Perturbations universelles sur six classifieurs

Analyse des résultats : reproduction de Moosavi-Dezfooli et al. (2017), comparaison CNN / Transformers, classes dominantes et défense par bruit gaussien. Novembre 2026.

En bref. (1) Une seule perturbation invisible (±10/255 par pixel) trompe **72 à 83 %** des 40 000 images de validation ImageNet pour les six réseaux testés, contre 6 à 18 % pour un témoin de même norme. (2) Les trois réseaux à attention (MaxViT, Swin, ViT) sont **plus difficiles à tromper** que les trois CNN (72–75 % contre 80–83 %) : il faut plus de passes, et leur perturbation se généralise moins bien. (3) Quatre architectures très différentes envoient les images vers **la même classe, « brain coral »** ; ResNet-50 vers « spider web », ViT vers « scoreboard ». (4) Un bruit gaussien σ = 20/255 à l'entrée ramène le fooling rate de ResNet-50 de 84,8 % à 10,5 % pour 4,5 points de précision, mais seulement face à un attaquant qui **ignore** la défense : l'expérience avec un attaquant adaptatif (EOT) est en cours.

1. Protocole

Nous suivons l'algorithme de l'article : on parcourt un ensemble d'images X ; pour chaque image que la perturbation courante v ne trompe pas encore, DeepFool calcule le plus petit pas qui la fait changer de classe, on l'ajoute à v, puis on projette v sur la boule ℓ_∞ de rayon ξ. On recommence des passes sur X jusqu'à tromper 80 % de X.

Paramètre	Valeur
Ensemble X (construction de v)	10 000 images : 10 par classe du jeu de validation ILSVRC2012
Évaluation	les 40 000 autres images de validation (disjointes de X)
Norme et rayon	ℓ_∞, ξ = 10/255 (norme ℓ_2 maximale possible : 15,2)
Arrêt	fooling rate ≥ 80 % sur X (δ = 0,2)
DeepFool	10 classes candidates, overshoot 0,02, 10 itérations au plus
Modèles	poids torchvision pré-entraînés, non modifiés ; entrée 224 × 224
Calcul	machine espagne de l'école (RTX A4000)

Fooling rate : proportion des images dont la classe prédite change quand on ajoute v. **Témoin** : les mêmes valeurs que v, mais avec les pixels mélangés au hasard ; il a exactement la même norme et mesure ce que fait la seule « quantité » de perturbation, sans sa structure.

2. Résultats sur les six modèles

Modèle	Famille	Préc. propre	Préc. avec v	Fooling éval.	Fooling sur X	Passes	ℓ_2	Témoin
ResNet-18	CNN	68,8 %	18,0 %	**79,6 %**	82,1 %	2	11,05	17,7 %
ResNet-50	CNN	80,5 %	17,1 %	**81,0 %**	82,3 %	4	10,46	9,5 %
ConvNeXt-B	CNN moderne	83,9 %	15,5 %	**82,9 %**	83,5 %	1	10,30	7,1 %
MaxViT-T	hybride conv. + attention	83,5 %	23,0 %	**74,9 %**	80,1 %	3	9,07	5,9 %
Swin-B	Transformer à fenêtres	83,3 %	23,9 %	**73,8 %**	80,5 %	5	9,21	7,9 %
ViT-B/16	Transformer	80,8 %	25,7 %	**71,9 %**	72,8 %*	9*	11,85	7,6 %

* ViT n'a jamais atteint 80 % sur X : le fooling rate plafonnait autour de 73 % depuis la 6e passe (figure 2) et le calcul a été arrêté pendant la 10e passe. La perturbation évaluée est celle du dernier checkpoint.

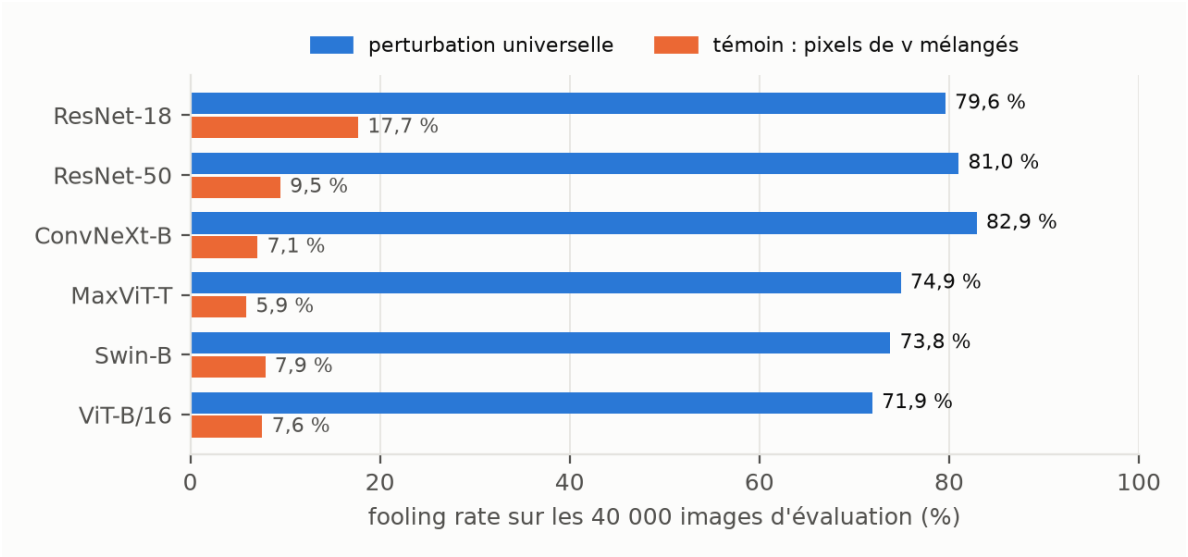


Figure 1. Fooling rate sur les 40 000 images d'évaluation, comparé au témoin de même norme.

2.1 La reproduction fonctionne sur toutes les architectures

Pour les six réseaux, la perturbation trompe entre 4 et 12 fois plus que le témoin de même norme : c'est sa **direction**, et non sa taille, qui trompe. ResNet-50 (81,0 %) se situe dans la fourchette de l'article (78–84 % pour VGG, GoogLeNet et ResNet-152). Le témoin de ResNet-18 est plus élevé (17,7 %) : ce réseau, le moins précis, est aussi le plus sensible à un bruit quelconque.

2.2 Les réseaux à attention résistent mieux

Les trois CNN atteignent 80–83 %, les trois réseaux à attention 72–75 %. L'écart apparaît de deux façons :

• **Le calcul est plus difficile.** ConvNeXt dépasse 80 % sur X dès la première passe, ResNet-18 en deux. MaxViT en demande trois, Swin cinq, et ViT n'y arrive pas en neuf (figure 2).

• **La perturbation se généralise moins bien.** Entre X et les images nouvelles, les CNN perdent 0,6 à 2,5 points ; MaxViT en perd 5,2 et Swin 6,7. La perturbation « colle » davantage aux images de X.

ConvNeXt est instructif : c'est un CNN modernisé pour ressembler à un Transformer (grands noyaux, recette d'entraînement moderne), et c'est le modèle le plus précis du lot. Il est pourtant le **plus** facile à tromper. La robustesse ne suit donc pas la précision, et l'élément qui distingue les trois modèles résistants est l'attention. C'est une hypothèse : avec un seul modèle par famille et un seul calcul par modèle, on ne peut pas séparer l'effet de l'architecture de celui de la recette d'entraînement.

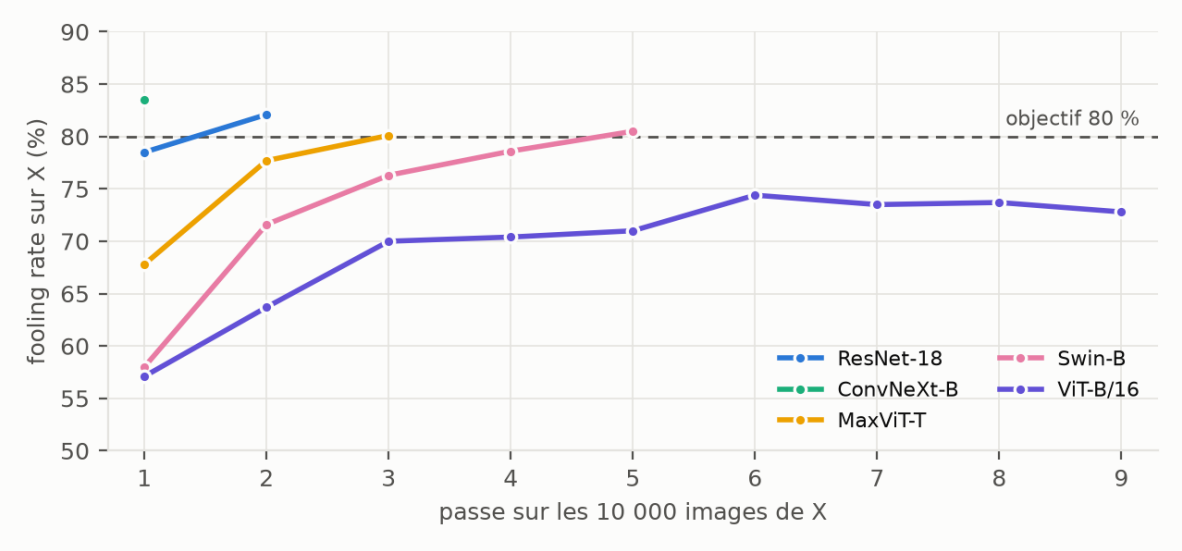


Figure 2. Fooling rate sur X à la fin de chaque passe. Pour MaxViT, la valeur de la passe 1 est celle enregistrée dans le checkpoint de reprise.

Attention à la comparaison. L'algorithme s'arrête dès 80 % sur X : il compare les modèles à objectif fixé, pas à effort fixé. Un CNN arrêté après une passe aurait peut-être dépassé 85 % avec cinq passes. Une comparaison plus juste fixerait le nombre de passes (option --max_passes) ou utiliserait l'algorithme par gradient, qui ne s'arrête pas sur une image déjà trompée.

3. Classes dominantes

Modèle	Classe dominante	Part des images trompées	Autres classes
ResNet-18	brain coral	18,4 %	shower curtain 15,7 %, mask 5,3 %, peacock 5,1 %
ResNet-50	spider web	97,5 %	—
ConvNeXt-B	brain coral	97,6 %	spider web 0,2 %
MaxViT-T	brain coral	98,9 %	—
Swin-B	brain coral	97,8 %	—
ViT-B/16	scoreboard	96,8 %	prayer rug 0,2 %

Comme dans l'article, la perturbation ne pousse pas chaque image vers une classe voisine : elle envoie presque tout vers **une seule classe**. Le fait marquant est que **quatre architectures sur six** (un petit CNN, un CNN moderne, un hybride, un Transformer à fenêtres) choisissent la même : brain coral. Ces perturbations ont été calculées indépendamment. Cela suggère que la classe dominante tient davantage aux **données d'entraînement** qu'à l'architecture : dans ImageNet, « brain coral » est peut-être une classe définie presque uniquement par une texture (des sillons sinueux et serrés), qu'un motif répété sur toute l'image suffit à imiter. « Spider web » est du même type (des fils fins sur fond uniforme). Pour ResNet-50, on l'avait vérifié : sur une image grise uniforme, v seule donne « spider web » avec une probabilité de 0,99.

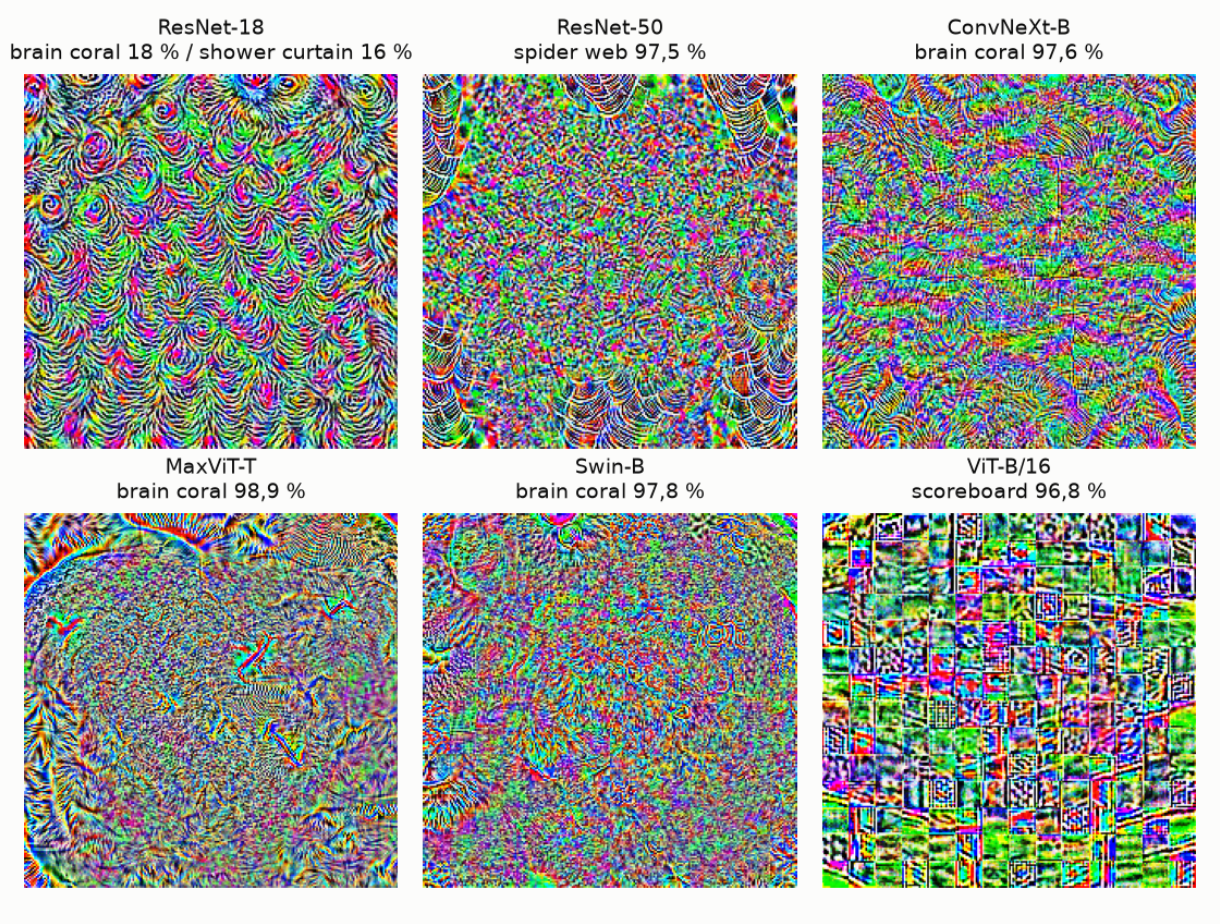


Figure 3. Les six perturbations, étirées sur [0, 1] pour être visibles (valeurs réelles dans ±10/255).

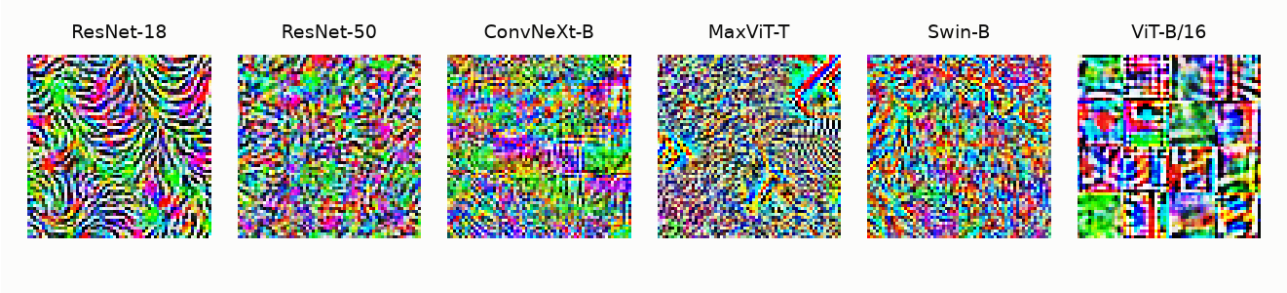


Figure 4. Zoom sur 64 × 64 pixels au centre de chaque perturbation.

Les images confirment cette lecture. La perturbation de ResNet-18 dessine des **sillons ondulés**, très proches d'un corail cérébral, et ce motif se retrouve, plus fin et plus bruité, chez ConvNeXt, MaxViT et Swin. ResNet-50 montre des **arcs de fils** sur les bords, comme une toile. ViT est à part : sa perturbation est un **quadrillage de 14 × 14 carrés** de 16 pixels, exactement la grille des patchs que découpe le modèle. Chaque carré contient son propre motif et les bords sont nets. La classe « scoreboard » (un tableau d'affichage fait de cases rectangulaires) est une interprétation plausible de ce quadrillage. ResNet-18, le seul sans classe dominante nette, est aussi le moins précis : sa perturbation hésite entre plusieurs textures (corail, rideau de douche, plumes de paon).

Ces interprétations restent des hypothèses visuelles. Deux tests simples permettraient de les vérifier : le test de l'image grise (class_stats.py) pour chaque modèle, et la **matrice de transfert** : la perturbation de Swin envoie-t-elle aussi ConvNeXt vers « brain coral » ?

4. Défense par bruit gaussien (ResNet-50)

La perturbation de l'article est construite avec des pas DeepFool **minimaux** : chaque image est poussée juste au-delà de la frontière (overshoot 0,02). Elle devrait donc être fragile. Pour le tester, on ajoute à chaque image, avant le classifieur, un bruit gaussien indépendant d'écart type σ. On utilise la perturbation ImageNet de ResNet-50 et le jeu de validation Imagenette (10 classes, 1 000 images : 100 par classe), sans recalculer v : l'attaquant **ignore** la défense.

σ (/255)	A : propres + bruit, bien classées	B : attaquées + bruit, bien classées	C : fooling rate sous le bruit	E : classées « spider web »
0	85,1 %	15,1 %	84,8 %	83,1 %
2	87,5 %	16,6 %	82,7 %	81,4 %
5	87,1 %	24,1 %	75,0 %	72,5 %
10	84,2 %	53,7 %	42,5 %	37,7 %
20	**80,6 %**	**77,0 %**	**10,5 %**	**0,1 %**
40	57,0 %	56,4 %	26,4 %	0,0 %

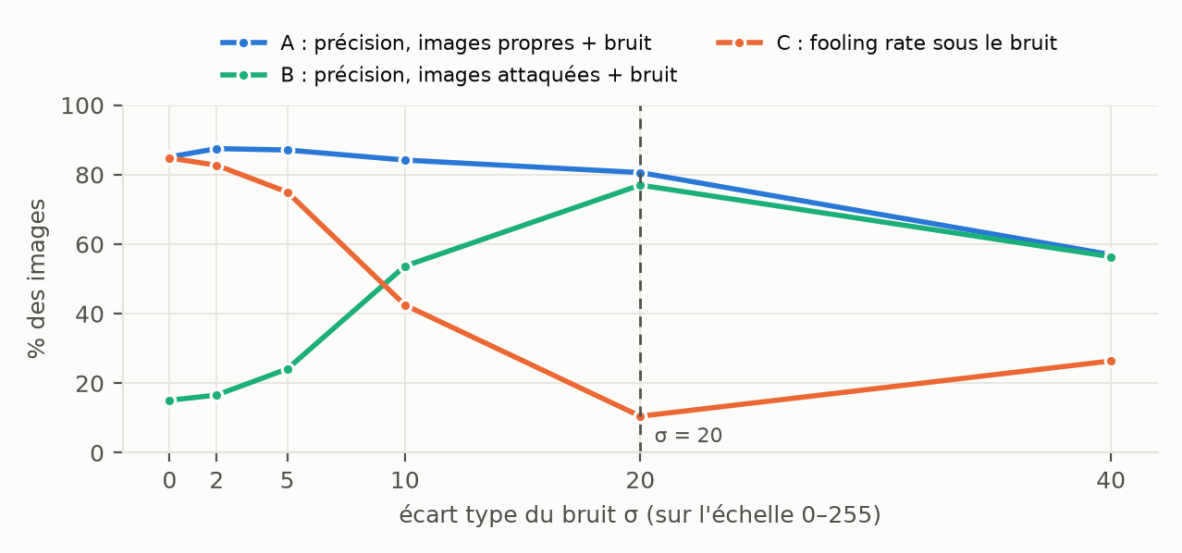


Figure 5. Coût (A) et efficacité (B, C) de la défense selon l'écart type du bruit.

Le bruit neutralise la perturbation. À σ = 20/255, le fooling rate tombe de 84,8 % à 10,5 %, soit le niveau du témoin (9,5 %), et plus aucune image n'est classée « spider web ». La précision sur les images propres ne perd que 4,5 points. C'est cohérent avec l'argument de marge : un pas minimal ne résiste pas à un bruit plus fort que lui. Au-delà, le bruit devient lui-même nuisible : à σ = 40, la précision propre tombe à 57 % et C remonte (26,4 %), car le bruit seul change déjà beaucoup de prédictions.

Ce résultat ne prouve pas que la défense est bonne. La littérature (Athalye et al. 2018) a montré que les défenses aléatoires de ce type tombent presque toujours face à un attaquant qui les connaît et calcule sa perturbation en moyenne sur le bruit (Expectation Over Transformation, EOT). Pour une perturbation universelle, Xu & Singh (ICML 2024) montrent qu'une perturbation robuste aux transformations existe. La seule question qui compte est donc : **que reste-t-il de la défense face à une perturbation calculée avec EOT ?**

5. Expérience en cours : attaquant adaptatif (EOT)

Le code a été étendu (--noise_std, --eot_samples, --algo sgd). Sur 500 images d'Imagenette, avec ResNet-50 et une défense à σ = 20, trois perturbations sont calculées sur les mêmes images, puis évaluées sous le bruit :

Perturbation	Construction	Question
Référence	algorithme de l'article, sans bruit (10 passes au plus)	point de comparaison sur 500 images
DeepFool + EOT	chaque pas DeepFool est la moyenne sur 4 copies bruitées (5 passes au plus)	l'algorithme de l'article suffit-il, une fois adapté ?
Gradient + EOT	montée de gradient de l'entropie croisée, en moyenne sur 4 tirages de bruit	une perturbation avec de la marge casse-t-elle la défense ?

À suivre en particulier : le fooling rate sous le bruit (colonne C à $\sigma = 20$), et l'image de la perturbation robuste. Si la défense tombe, quelle classe domine, et la perturbation devient-elle une texture plus grossière (basse fréquence), qui survit au bruit ?

6. Limites et prochaines étapes

Limites. Un seul calcul par modèle : sur GPU, deux calculs identiques ne donnent pas exactement la même perturbation, et l'ordre aléatoire des images change le résultat. Les écarts de un ou deux points ne sont pas significatifs. Les modèles ont été arrêtés à des stades différents (objectif atteint ou plafond). X est tiré du jeu de validation et non du jeu d'entraînement comme dans l'article. La défense par bruit n'a été évaluée que sur ResNet-50 et Imagenette.

Prochaines étapes, par ordre d'intérêt :

• **Résultat de l'EOT** (en cours) : la défense par bruit résiste-t-elle à un attaquant adaptatif, et à quel coût ?

• **Classe dominante sous EOT** : l'évolution de la classe dominante quand la perturbation doit survivre au bruit. Notre revue de littérature n'a pas trouvé d'étude sur ce point (confiance moyenne).

• **Matrice de transfert** entre les six modèles, et test de l'image grise pour chacun : la « brain coral » de Swin trompe-t-elle ConvNeXt ?

• **Défense par bruit sur les six modèles** (eval_noise.py) : les Transformers, déjà plus robustes, ont-ils besoin de moins de bruit ?

• **Comparaison à effort égal** : même nombre de passes pour tous les modèles, ou algorithme par gradient.